DESAFIO DE ARQUITETURA - EINSTEIN+

Agente de Completude de Normativos e Cadeia de Valor

O que falta nos normativos e nos processos de cada área, provado requisito a requisito, com evidência citada e decisão humana.

Rogério Barbosa - proposta de arquitetura, revisão 7 - 2 de novembro de 2026

O PROBLEMA

O que falta, área por área

~700

responsáveis por normativos internos

~25

acreditações, com a JCI, além da legislação vigente

2

camadas: determinística (base do Einstein) e livre (mercado)

Busca por similaridade traz os trechos mais parecidos, não a lista de obrigações.

Um requisito que a busca não recupera some da análise sem deixar rastro.

O QUE A PROPOSTA GARANTE

O que “determinística” significa aqui

O sistema garante

- Todo requisito do referencial, listado na base do Einstein, entra no universo da análise
- Todo requisito aplicável termina com uma classificação, inclusive “inconclusivo”
- Toda conclusão cita o trecho, com documento, versão e localizador
- Incluir, revisar ou atualizar sai de uma regra, não do modelo

Como o sistema garante os requisistos

- O modelo interpreta todos os requisitos com suporte e revisão humana
- Ausência de evidência é descumprimento e vira pendência.

SLIDE 3 DO DESAFIO

Do desenho funcional à arquitetura

Elemento do desenho	Como a solução o realiza
Sub-agente de processos	Agente no Teams liga cada atividade a um processo do RAG
Sub-agente de normativos	Rotina A indexa por versão e validade e busca a evidência de cada requisito
Completude determinística	O executor lista os requisitos na base do Einstein e avalia um por chamada
Completude livre	A Rotina B carrega práticas periodicamente
Saída	Uma regra define incluir, revisar ou atualizar, agrupado por normativo e processo
Guardrail	Proibições validadas no executor e Guardrail da plataforma no gateway

O RESULTADO

Três tipos de achado, todos com evidência

A - Cobertura de requisito

Os normativos cobrem o que o referencial exige?

Exemplo: o procedimento de coleta não explicita o critério de escalonamento que a versão vigente do requisito exige.

Incluir, revisar ou atualizar o normativo

B - Lacuna na Cadeia de Valor

O que a área faz está mapeado e normatizado?

Exemplo: o gestor confirma que a área faz coleta domiciliar, e não há processo mapeado para ela.

Incluir o processo ou o normativo

C - Prática de mercado

O que o mercado pratica e a base ainda não tem?

Exemplo: registro do horário de coleta e de recebimento de cada amostra, com alerta de tempo excedido.

Oportunidade, nunca obrigação

O que é reuso e o que é novo na Einstein+

R - implantado na plataforma | H - previsto ou em homologação | N - novo | E - fora da plataforma

Canal	**H - Copilot Studio** Teams, homologação dez-26	**H - Conectores de Canal** aviso no Teams, dez-26	**N - Interface de revisão** ocupa o Front TBD		
Sub-agente de processos	**N - Agente de contexto** sobre R - LangChain, set-26	**H - Memória Redis** curto prazo, set-26			
Serviço de Completude	**N - API** 4 endpoints	**N - Service Bus** ocupa a Fila TBD	**N - Orquestrador** Durable Task	**N - 2 executores** sem estado	**N - PostgreSQL** registro
IA da plataforma	**R - LLM Gateway** LiteLLM, mar-26	**H - Guardrail** no gateway, dez-26	**R - Haystack RAG** set-26	**R - Qdrant** abr-26	
Carga periódica	**R - Airflow** agenda, set-26	**N - Rotina A** acervo interno	**N - Rotina B** benchmark	**N - Blob** cópias externas	
Fora da plataforma	**E - Base do Einstein** JCI e legislação, só leitura	**E - SharePoint** normativos e processos (premissa)	**E - Fontes externas** allowlist do Compliance		

DADOS

Onde cada dado fica

E - só leitura

Base do Einstein

JCI e legislação. Nenhuma rotina da solução a carrega.

R - conhecimento

RAG

Normativos, Cadeia de Valor e práticas, por versão, validade e permissões.

H - descartável

Memória Redis

Conversa e rascunhos do agente. Expira; só o agente usa.

N - auditável

PostgreSQL

Registro das análises, pedido, universo, itens, resultado e decisões.

N - procedência

Blob

Cópias das fontes externas que sustentam os itens C.

Onde a JCI e a legislação estão gravadas nesta solução?

Estão na base do Einstein, que a solução só lê. O PostgreSQL guarda só quais requisitos, em que versão, entraram em cada análise.

ANÁLISE DEMORADA

Aceita em segundos, conduzida com prazo

1 - Pedido

A API valida alçada e IDs, grava a análise, publica o comando e devolve 202 com Location

2 - Fila

O Service Bus guarda o comando mesmo com o orquestrador parado e descarta duplicatas

3 - Orquestrador

Uma instância por análise; slot com limite por área e por solicitante

4 - Executores

Até 4 requisitos em paralelo; prazo por etapa; falha vira inconclusivo

5 - Fim

Resultado único, estado final e aviso sem conteúdo no Teams

Nada se perde

A fila guarda os pedidos; a instância retoma do histórico sem refazer requisitos.

Nada se duplica

Idempotency-Key, MessageId e instância com o id da análise; um resultado só.

Nada fica preso

Prazo vencido ou falha viram inconclusivo com motivo; a análise sempre termina.

APIS

Quatro endpoints, um contrato assíncrono

Base **/v1/completeness-analyses** - OAuth 2.0 com Entra ID - escritas com Idempotency-Key

Endpoint	Entrada	Saída	Para quê
POST /	recorte, referenciais, data de corte e contexto confirmado	202, Location e Retry-After	pedir, (é a confirmação)
GET /{id}	If-None-Match	estado, etapa e progresso; 304 sem mudança	acompanhar
GET /{id}/results	view summary ou full; cursor e filtros	agrupado por normativo e processo	consultar
POST /{id}/reviews	alvo, ação, justificativa e versão esperada	201 com a decisão registrada	decidir

O Copilot Studio só recebe **summary**. Trechos de normativos só na projeção **full**, da interface de revisão.

SAÍDA

Incluir, revisar ou atualizar: por regra

Situação	Recomendação
A - Nenhum normativo vigente cobre o requisito	Incluir
A - Cobertura parcial, e todos os normativos citados são anteriores à versão vigente do requisito	Atualizar
A - Cobertura parcial por outro motivo, ou normativos conflitantes	Revisar
B - Atividade sem processo, ou processo sem normativo	Incluir processo ou normativo
C - Prática não abordada, ou parcialmente abordada	Incluir ou revisar, como oportunidade

Por que regra, e não o modelo

O modelo classifica e descreve o que falta. A regra decide o verbo e fica registrada no item.

A data indica a causa provável da cobertura parcial, a decisão final é humana.

Coberto - nenhuma recomendação.
Inconclusivo - pendência

DECISÃO 1 DE 3

ADR-01 - Enumerar na base do Einstein

Escolha

A cada análise, listar na base do Einstein todos os requisitos do referencial vigentes na data de corte e percorrê-los um a um. O PostgreSQL guarda só quais requisitos, em que versão, entraram.

Alternativas descartadas

Catálogo próprio no PostgreSQL: duplica a base e exige sincronização. RAG top-k ou supervisor autônomo: não provam que nenhum requisito ficou de fora.

Trade-off

A completude depende de a base listar tudo por referencial e data, o que ainda é premissa. Em troca: prova por contagem e nenhuma cópia a sincronizar.

COMO SE PROVA

Em toda análise: listados = aplicáveis + excluídos com motivo; aplicáveis = soma das classificações A.

DECISÃO 2 DE 3

ADR-02 - Fila só na entrada

Escolha

Service Bus só entre a API e o orquestrador. Um orquestrador durável, no Durable Task Scheduler, chama dois executores por activities, com prazos, novas tentativas e fan-in nativos.

Alternativas descartadas

Fila em todo o caminho, com filas de tarefas e de resultados: mais peças para reproduzir o que o motor já faz. Também: coordenador próprio, coreografia, Batch do Haystack, Temporal.

Trade-off

Com o motor parado, as análises em curso pausam: a SKU do piloto não tem alta disponibilidade. Nada se perde: a fila guarda os pedidos e a instância retoma do histórico.

COMO SE PROVA

Motor parado no meio da avaliação: retoma sem refazer requisitos. Comando duplicado: uma instância e um resultado.

DECISÃO 3 DE 3

ADR-03 - Benchmark por carga periódica

Escolha

A Rotina B coleta periodicamente, por tema, das fontes da allowlist; indexa no RAG com fonte e data e guarda a cópia no Blob. A análise só compara.

Alternativas descartadas

Pesquisa externa a cada análise: mais atual, mas mais lenta, mais cara e com a internet no caminho da análise. Curadoria antes de indexar: fica como evolução.

Trade-off

Práticas defasadas até a próxima carga; a qualidade dos itens C depende da allowlist e da revisão. Em troca, nenhuma consulta externa leva conteúdo interno.

COMO SE PROVA

Nenhuma chamada de análise alcança a internet; todo item C tem fonte, data da coleta e cópia.

MVP em quatro entregas

Piloto: uma unidade, laboratório clínico, macroprocesso pré-analítico, com os referenciais definidos pelo Compliance.

F1

Fundação

Identidade, gateway, Service Bus, Scheduler, PostgreSQL, Copilot e agente com memória

Prova: o Copilot alcança o agente e um comando inicia e termina uma instância

F2

Acervo e base

Rotina A com gate de dados, índices e acesso à base do Einstein

Prova: listagem completa de um referencial na data de corte

F3

Análise ponta a ponta

Cenários 1 a 4, sem benchmark, com a regra de recomendação e o aviso

Prova: motor parado e activity repetida não perdem nem duplicam

F4

Benchmark, revisão e aceite

Rotina B, itens C, interface de revisão, avaliação e carga

Prova: recall de 95% e precisão de 85% nas lacunas críticas, metas a negociar

Fora do MVP: cancelamento, reanálise automática, curadoria prévia do benchmark, memória longa, MCP e expansão aos 700 responsáveis.

PREMISSAS ESCRITAS, COMO PEDE O SLIDE 6

Premissas e o que precisa de resposta

Premissas declaradas

- A base do Einstein lista os requisitos por referencial e data, com versão e vigência
- Normativos e Cadeia de Valor estão no SharePoint, com IDs estáveis
- Os itens previstos da Einstein+ estarão disponíveis para o MVP
- Toda inferência passa pelo LLM Gateway; o domínio não fixa modelo nem região
- Nenhum dado de paciente é necessário

Perguntas para o Einstein

- **O1** A base lista todos os requisitos de um referencial numa data? Por qual interface?
- **O2** Qual critério diz quais requisitos se aplicam à área? Até lá, todos se aplicam
- **O3** Copilot Studio, Memória Redis, Conectores e Guardrail chegam nas datas do slide 4?
- **O4** O Copilot Studio alcança um agente em LangChain?

EM UMA FRASE

Os requisitos vêm da base do Einstein. O RAG só busca evidência. Uma regra decide a ação e uma pessoa decide o resto.

Perguntas - documentos de apoio: especificação, DDA e quatro RDAs